



SmartOnBoard AI: Plataforma inteligente de onboarding empresarial

Sebastian Mira Castro

Institución Universitaria Politécnico Gran Colombiano
Ingeniería Industrial
Bogotá D.C., Colombia
2026

Índice

1. TITULO DE LA PROPUESTA:	3
2. PLANTEAMIENTO DEL PROBLEMA:	3
3. OBJETIVOS:	5
4. JUSTIFICACIÓN:	5
5. MARCO TEÓRICO:	6
6. METODOLOGÍA:	9
7. RESULTADOS:	11
8. CRONOGRAMA:	13
9. BIBLIOGRAFÍA:	15

El presente trabajo de grado describe el diseño, desarrollo e implementación de **SmartOnboard AI**, una plataforma web inteligente orientada a automatizar y personalizar el proceso de incorporación (onboarding) de nuevos empleados en organizaciones empresariales. El problema abordado es la ineficiencia estructural de los procesos

tradicionales de onboarding: la información institucional se encuentra dispersa en múltiples repositorios sin indexación semántica, las áreas de Recursos Humanos dedican una parte importante de su tiempo a resolver preguntas repetitivas y no existen mecanismos objetivos para medir el avance del empleado durante sus primeras semanas. El marco teórico se fundamenta en los avances recientes de la inteligencia artificial generativa: los modelos de lenguaje de gran escala (LLM), la generación aumentada por recuperación (RAG), los agentes autónomos basados en el paradigma ReAct, el ajuste fino eficiente de modelos mediante adaptación de bajo rango (LoRA) y la evaluación automática de sistemas de lenguaje con métricas tipo RAGAS. El objetivo general consiste en desarrollar una plataforma de software que integre dichas tecnologías para reducir el tiempo de incorporación efectiva y proporcionar métricas objetivas de seguimiento. La metodología corresponde a un proyecto de desarrollo tecnológico aplicado con enfoque cuantitativo, gestionado mediante Scrum adaptado a trabajo individual y estructurado en cuatro fases: construcción del backend y del pipeline RAG; implementación del agente conversacional y de las interfaces de usuario; evaluación automática y ajuste fino del modelo; y cierre, pruebas y documentación. A la fecha de elaboración de este documento, las dos primeras fases se encuentran completadas y la tercera en ejecución: la plataforma cuenta con doce vistas funcionales, una API REST con autenticación JWT y control de acceso basado en roles, un pipeline de ingesta y búsqueda semántica de documentos en operación, un agente conversacional construido con LangGraph que responde citando las fuentes documentales, y una primera iteración de ajuste fino con LoRA sobre un modelo de código abierto, cuya comparativa frente al modelo base evidenció una mejora medible en la calidad de las respuestas. Como resultados finales se espera entregar la plataforma desplegada en un ambiente de demostración, el informe de evaluación comparativa, el repositorio de código documentado y el presente informe de trabajo de grado.

Palabras Claves: Onboarding empresarial, inteligencia artificial, modelos de lenguaje de gran escala (LLM), generación aumentada por recuperación (RAG), agentes autónomos, ajuste fino, LoRA, RAGAS, ingeniería de software.

1. TITULO DE LA PROPUESTA:

SmartOnboard AI: Plataforma inteligente de onboarding empresarial basada en agentes de inteligencia artificial, generación aumentada por recuperación (RAG) y ajuste fino de modelos de lenguaje.

2. PLANTEAMIENTO DEL PROBLEMA:

La incorporación de nuevos empleados constituye uno de los procesos más críticos y, a la vez, menos tecnificados de la gestión del talento humano. En la mayoría de las organizaciones la información institucional —manuales, políticas, reglamentos y procesos— se encuentra dispersa en múltiples formatos y repositorios sin indexación semántica, lo que obliga al empleado nuevo a depender de personas específicas del área de Recursos Humanos para resolver preguntas recurrentes y de bajo valor estratégico. Estudios del sector de gestión del talento humano señalan que una incorporación deficiente puede extender en varias semanas el tiempo que tarda un nuevo colaborador en alcanzar su nivel óptimo de productividad, con el consecuente impacto económico para la organización y el deterioro de la experiencia del empleado. Como

antecedente tecnológico, la madurez reciente de los modelos de lenguaje de gran escala (LLM), de la generación aumentada por recuperación (RAG) y de las técnicas de ajuste fino eficiente permite hoy abordar esta problemática con soluciones que eran inviables hace pocos años, bajo el supuesto —sustentado en la literatura— de que la recuperación de contexto documental verificable y la especialización del modelo al dominio mejoran la calidad de las respuestas generadas.

El análisis de la situación problemática permite identificar cinco elementos estructurales: (a) la dispersión de la información institucional en formatos heterogéneos sin posibilidad de consulta unificada; (b) la dependencia operativa del personal de Recursos Humanos para responder preguntas repetitivas; (c) la ausencia de mecanismos de seguimiento objetivo del progreso individual del empleado durante sus primeras semanas; (d) la desconexión entre las herramientas empresariales de gestión de tareas, como Jira, y el proceso de onboarding; y (e) la falta de instrumentos que evalúen de manera automática y cuantitativa la calidad de la información que se entrega al empleado.

Con base en los elementos anteriores, la pregunta de investigación que orienta el presente trabajo se formula en los siguientes términos: ¿Cómo puede una plataforma de software basada en agentes de inteligencia artificial, generación aumentada por recuperación y ajuste fino de modelos de lenguaje automatizar y personalizar el proceso de onboarding empresarial, de manera que se reduzca el tiempo de incorporación efectiva de los nuevos empleados y se disponga de métricas objetivas de seguimiento y de calidad de las respuestas? Las variables principales que intervienen son: como variable independiente, la configuración del sistema de inteligencia artificial (modelo base frente a modelo ajustado con LoRA, y presencia o ausencia de contexto recuperado mediante RAG); como variables dependientes, la calidad de las respuestas —medida con los indicadores de fidelidad, relevancia y precisión de contexto— y el tiempo de incorporación efectiva del empleado; y como variables intervinientes, la calidad y cobertura de la documentación cargada por la organización. La relación entre estas variables se fundamenta en la literatura sobre RAG (Lewis y otros, 2020) y ajuste fino eficiente (Hu y otros, 2022), que sostiene que la incorporación de contexto documental verificable y la especialización del modelo al dominio incrementan la fidelidad y relevancia de las respuestas. Para efectos del trabajo, se entiende por onboarding el proceso de incorporación de un nuevo empleado a la organización; por RAG, la técnica que recupera fragmentos documentales relevantes y los entrega al modelo como contexto para generar la respuesta; y por ajuste fino, la especialización de un modelo de lenguaje preentrenado mediante el entrenamiento de adaptadores de bajo rango sobre datos del dominio.

3. OBJETIVOS

3.1 OBJETIVO GENERAL:

Desarrollar una plataforma de software inteligente que automatice y personalice el proceso de onboarding empresarial mediante la integración de agentes de inteligencia artificial basados en generación aumentada por recuperación (RAG) y ajuste fino de modelos de lenguaje, con el fin de reducir el tiempo de incorporación efectiva de nuevos empleados y proporcionar métricas objetivas de evaluación del proceso.

3.2. OBJETIVOS ESPECÍFICOS:

OE1. Diseñar e implementar una arquitectura de backend escalable basada en FastAPI y bases de datos relacionales y vectoriales, que soporte el procesamiento asíncrono de documentos, la gestión de embeddings semánticos, la autenticación con JWT y el control de acceso basado en roles, departamentos y niveles de antigüedad.

OE2. Construir un agente conversacional autónomo utilizando LangGraph con el patrón ReAct, capaz de recuperar información contextual mediante RAG, clasificar las consultas por categoría y nivel de profundidad, y generar respuestas que citen las fuentes documentales verificables de la organización.

OE3. Desarrollar las interfaces de usuario del sistema —panel administrativo de Recursos Humanos y portal del empleado— con Next.js y TailwindCSS, integradas con la API del backend para la gestión de documentos, planes de onboarding, tareas sincronizables con Jira y conversaciones con el agente en tiempo real.

OE4. Implementar un pipeline de evaluación automática de la calidad del agente basado en métricas del framework RAGAS, y ejecutar un proceso de ajuste fino supervisado con LoRA sobre un modelo de lenguaje de código abierto, documentando la comparativa de desempeño entre el modelo base y el modelo especializado.

4. JUSTIFICACIÓN:

El desarrollo del presente trabajo de grado se justifica desde cuatro dimensiones complementarias: técnica, económica y organizacional, social y académica.

Justificación técnica. El proyecto integra en una arquitectura cohesiva las tecnologías que definen el estado del arte del desarrollo de software con inteligencia artificial: pipelines de generación aumentada por recuperación (RAG) con bases de datos vectoriales, agentes autónomos con clasificación de consultas y trazabilidad de decisiones, evaluación automática de sistemas de lenguaje mediante métricas cuantitativas, y ajuste

fino de modelos de código abierto mediante adaptación de bajo rango (LoRA). A diferencia de las soluciones que se limitan a consumir servicios de inteligencia artificial a través de interfaces de programación comerciales, esta propuesta construye, evalúa y especializa modelos, lo que constituye un nivel de profundidad técnica acorde con un trabajo de grado de ingeniería y demuestra dominio integral del ciclo de vida de un sistema de IA en producción.

Justificación económica y organizacional. El onboarding deficiente representa un costo directo y medible para las organizaciones: horas del personal de Recursos Humanos dedicadas a resolver preguntas repetitivas de bajo valor estratégico y semanas de productividad reducida del empleado nuevo mientras alcanza su rendimiento óptimo. Una plataforma que automatice la resolución de consultas con fuentes verificables y el seguimiento del proceso tiene aplicabilidad transversal a industrias y tamaños de empresa. Adicionalmente, su arquitectura multiempresa (multi-tenant), en la que una única instancia del sistema atiende a múltiples organizaciones con espacios de conocimiento aislados, le otorga viabilidad real como producto de software como servicio (SaaS) más allá del contexto académico.

Justificación social. La experiencia de incorporación condiciona la retención del talento y el bienestar laboral de los nuevos colaboradores. Un acompañamiento disponible de forma permanente, que responda en lenguaje natural y con fuentes verificables, reduce la incertidumbre y la ansiedad propias del ingreso a una organización, y democratiza el acceso a la información institucional con independencia del horario, de la sede de trabajo o de la disponibilidad del personal de apoyo, lo cual resulta especialmente relevante en esquemas de trabajo remoto e híbrido.

Justificación académica. El desarrollo del proyecto exige la apropiación y aplicación práctica de conocimientos de múltiples disciplinas de la Ingeniería de Software: arquitectura de aplicaciones web, diseño de API REST, programación asíncrona, modelado de datos relacionales y vectoriales, seguridad y control de acceso basado en roles, procesamiento de lenguaje natural y prácticas de MLOps. Esta transversalidad convierte el trabajo en una demostración de madurez integral como ingeniero de software, y las competencias desarrolladas corresponden a los perfiles profesionales de mayor demanda actual en la industria, como ingeniero de inteligencia artificial e ingeniero de MLOps.

5. MARCO TEÓRICO

Marco referencial y conceptual

Onboarding empresarial. Se entiende por onboarding el conjunto de actividades mediante las cuales una organización incorpora a un nuevo colaborador: entrega de información institucional, asignación de tareas iniciales, presentación del equipo de trabajo y acompañamiento durante las primeras semanas. La literatura de gestión del talento coincide en que la calidad de este proceso incide directamente en el tiempo que tarda el empleado en alcanzar su productividad plena y en su permanencia en la organización.

Marco histórico: de los chatbots de reglas a los modelos generativos. Los asistentes conversacionales empresariales evolucionaron desde sistemas de reglas y respuestas predefinidas, pasando por modelos de clasificación de intenciones, hasta los actuales modelos de lenguaje de gran escala. El punto de inflexión fue la arquitectura Transformer (2017) y la posterior aparición de modelos generativos de propósito general, que hicieron posible responder preguntas abiertas en lenguaje natural. Sin embargo, estos modelos presentan dos limitaciones para el uso corporativo: desconocen la información interna de cada organización y pueden generar contenido no verificable (alucinaciones), limitaciones que las técnicas descritas a continuación buscan resolver.

Modelos de lenguaje de gran escala (LLM). Los LLM son redes neuronales basadas en la arquitectura Transformer, entrenadas sobre grandes volúmenes de texto, capaces de comprender y generar lenguaje natural. Modelos de código abierto como Llama 3 de Meta [7] permiten su descarga, ejecución local y especialización, lo que habilita escenarios empresariales donde la información sensible no debe abandonar la infraestructura de la organización.

Embeddings y búsqueda semántica. Un embedding es una representación vectorial de un texto que captura su significado, de modo que textos semánticamente similares quedan próximos en el espacio vectorial. La similitud entre una consulta y los fragmentos de un documento se calcula mediante métricas como la similitud del coseno, lo que permite recuperar información relevante aunque no exista coincidencia literal de palabras. Las bases de datos vectoriales, como la extensión pgvector de PostgreSQL, almacenan y consultan estos vectores de manera eficiente.

Generación aumentada por recuperación (RAG). Propuesta por Lewis y otros [1], la técnica RAG combina un componente de recuperación de información con un modelo generativo: ante una consulta, el sistema recupera primero los fragmentos documentales más relevantes y los entrega al modelo como contexto para generar la respuesta. Este enfoque reduce las alucinaciones, permite citar fuentes verificables y mantiene actualizado el conocimiento del sistema sin reentrenar el modelo, pues basta con actualizar la base documental [10]. En el presente proyecto, RAG constituye el núcleo del agente: el pipeline extrae el texto de los documentos corporativos, lo divide en fragmentos con solapamiento, genera sus embeddings y los indexa para la búsqueda semántica posterior.

Agentes autónomos y paradigma ReAct. El paradigma ReAct (razonamiento y actuación) [4] estructura el comportamiento de un agente de lenguaje como ciclos de razonamiento, acción y observación, lo que le permite decidir qué herramienta utilizar en cada paso: consultar la base de conocimiento, clasificar la pregunta o generar la respuesta final. El framework LangGraph [5] permite modelar este comportamiento como un grafo de estados con nodos y transiciones explícitas, lo que aporta trazabilidad y control sobre el flujo del agente.

Ajuste fino eficiente: LoRA y QLoRA. La adaptación de bajo rango (LoRA) [2] permite especializar un modelo de lenguaje entrenando únicamente matrices de bajo rango que se suman a los pesos originales congelados, reduciendo los parámetros entrenables a

menos del uno por ciento del total. Combinada con la cuantización de cuatro bits (QLoRA), hace viable el ajuste fino en hardware accesible, como las GPU gratuitas de Google Colab. Las bibliotecas PEFT y Transformers de Hugging Face [6] proporcionan la implementación de referencia utilizada en este trabajo.

Evaluación automática de sistemas RAG. El framework RAGAS [3] define métricas cuantitativas para evaluar pipelines de generación aumentada: fidelidad (faithfulness), que mide si la respuesta se sostiene en el contexto recuperado; relevancia de la respuesta (answer relevancy); y precisión del contexto (context precision). Estas métricas, junto con el paradigma de evaluación mediante modelos jueces (LLM-as-judge), permiten monitorear de forma continua y sin intervención humana la calidad de un sistema conversacional en operación.

Marco conceptual de la solución. La plataforma adopta una arquitectura multiempresa (multi-tenant), en la que cada organización dispone de su propio espacio de conocimiento aislado, y un esquema de control de acceso basado en roles (RBAC) con tres niveles combinables: por departamento, por nivel de antigüedad del cargo y por banderas especiales de Recursos Humanos y gerencia. El filtrado de permisos se aplica en la capa de datos antes de la búsqueda semántica, de modo que el agente nunca recibe fragmentos de documentos a los que el usuario no tiene acceso.

Marco legal. Por tratarse de un sistema que procesa documentos corporativos e información de empleados, el desarrollo considera el régimen colombiano de protección de datos personales establecido en la Ley 1581 de 2012 y sus decretos reglamentarios [9], en particular los principios de finalidad, acceso restringido y seguridad de la información, que se materializan en la plataforma mediante el control de acceso por roles, el aislamiento por empresa y la autenticación de los usuarios.

Consideración ambiental. La elección de técnicas de ajuste fino eficiente (LoRA con cuantización de cuatro bits) y de modelos de tamaño reducido responde también a un criterio de sostenibilidad computacional: frente al reentrenamiento completo de un modelo, estas técnicas disminuyen en órdenes de magnitud el consumo energético y los recursos de cómputo requeridos.

Estado del Arte

En el ámbito mundial, la literatura reciente demuestra la madurez individual de los componentes que integra este proyecto: la generación aumentada por recuperación cuenta con fundamentos consolidados [1], [10]; los agentes de lenguaje con razonamiento estructurado son objeto de investigación activa [4] y disponen de frameworks de producción [5]; y el ajuste fino eficiente se ha convertido en la práctica estándar para especializar modelos de código abierto [2], [6]. En paralelo, las plataformas comerciales de onboarding se concentran en la gestión documental y de tareas, y los asistentes conversacionales empresariales disponibles suelen limitarse a chatbots de respuestas predefinidas o a integraciones directas con interfaces de programación de modelos comerciales, sin recuperación verificable sobre la documentación propia de la empresa, sin control de acceso a nivel de fragmento documental y sin mecanismos de evaluación

automática de la calidad de sus respuestas. En el contexto nacional y latinoamericano, la adopción de estas tecnologías en procesos de gestión humana es aún incipiente, lo que representa una oportunidad para el desarrollo de soluciones locales.

La brecha que este trabajo busca cerrar es, por tanto, la integración de dichos componentes en una plataforma única de onboarding que combine: recuperación semántica con permisos granulares, agentes con trazabilidad de decisiones, evaluación continua y cuantitativa de la calidad, y especialización del modelo al dominio de cada organización. Con fundamento en las investigaciones previas citadas, existe evidencia razonable de que esta integración contribuirá con probabilidades de éxito a la solución del problema planteado, hipótesis que el proyecto verifica empíricamente mediante la comparativa de desempeño entre el modelo base y el modelo especializado.

6. METODOLOGÍA

Enfoque metodológico. El presente trabajo corresponde a un proyecto de desarrollo tecnológico aplicado con enfoque cuantitativo: se construye un artefacto de software que materializa la solución propuesta y se evalúa su desempeño mediante indicadores numéricos verificables. La gestión del desarrollo adopta el marco ágil Scrum adaptado a trabajo individual, con sprints de dos semanas, control de versiones en GitHub con commits por funcionalidad, y revisiones periódicas de avance con el director del trabajo de grado. Esta elección se argumenta en la naturaleza iterativa e incremental del producto: cada fase entrega componentes funcionales verificables que sirven de base a la siguiente, lo que reduce el riesgo técnico y permite validar decisiones de arquitectura de manera temprana.

Definición de hipótesis. La hipótesis de trabajo se formula en los siguientes términos: H1 — Un agente conversacional que combina la recuperación aumentada (RAG) sobre la documentación propia de la organización con un modelo de lenguaje ajustado mediante LoRA produce respuestas de mayor calidad —medida en fidelidad, relevancia y precisión de contexto— que el mismo modelo base sin especialización ni contexto recuperado. La hipótesis establece una relación cuantitativa y verificable entre variables, es consistente con los hechos documentados en la literatura sobre RAG y ajuste fino eficiente, y está formulada de modo que pueda descartarse si la comparativa experimental no evidencia diferencias.

Variables e indicadores. Se identifican las siguientes variables: como variable independiente, la configuración del sistema de inteligencia artificial, con dos dimensiones manipulables: el modelo utilizado (base o ajustado con LoRA) y la presencia o ausencia de contexto recuperado mediante RAG. Como variables dependientes, la calidad de la respuesta generada y la eficiencia del proceso de onboarding. Como variables intervinientes, la calidad y cobertura de la documentación cargada por la organización y el tamaño del conjunto de datos de ajuste, las cuales se controlan manteniendo fija la base documental durante las mediciones.

Operacionalización de las variables. La variable dependiente principal, calidad de la respuesta (definición nominal), se operacionaliza así: dimensión fidelidad — indicador

faithfulness, proporción del contenido de la respuesta sustentado en el contexto recuperado, índice de 0 a 1 con ponderación del 40% en el puntaje global; dimensión relevancia — indicador answer relevancy, correspondencia semántica entre pregunta y respuesta, índice de 0 a 1 con ponderación del 40%; dimensión uso del contexto — indicador context precision, pertinencia de los fragmentos recuperados, índice de 0 a 1 con ponderación del 20%. El puntaje global se calcula como la suma ponderada de los tres indicadores. La segunda variable dependiente, eficiencia del proceso, se operacionaliza mediante la tasa de resolución de consultas sin intervención humana (porcentaje) y el tiempo promedio de incorporación efectiva (días).

Presentación de etapas. El proyecto se estructura en cuatro fases alineadas con los objetivos específicos. Fase 1 — Backend y pipeline RAG (OE1, semanas 1 a 6, completada): configuración del entorno y repositorio; diseño del modelo de datos relacional con once entidades incluyendo el esquema de permisos por departamento, rol y antigüedad; implementación de la API REST con FastAPI, autenticación JWT y control de acceso; construcción del pipeline de ingesta con extracción de texto de archivos PDF, DOCX y TXT, fragmentación con ventana de 500 caracteres y solapamiento de 50, generación de embeddings con el modelo all-MiniLM-L6-v2 de sentence-transformers e indexación para búsqueda por similitud del coseno. Fase 2 — Agente conversacional y frontend (OE2 y OE3, semanas 6 a 10, completada): implementación del agente con LangGraph como grafo de tres nodos (recuperación, clasificación y generación) siguiendo el patrón ReAct, con clasificación de consultas en cinco categorías y tres niveles de profundidad; desarrollo de las doce vistas del frontend con Next.js y TailwindCSS, tanto del panel administrativo de Recursos Humanos como del portal del empleado, e integración completa con la API. Fase 3 — Evaluación y ajuste fino (OE4, semanas 11 a 15, en ejecución): implementación del pipeline de evaluación automática con las métricas descritas, calculadas tras cada interacción; preparación del conjunto de datos de ajuste con quince pares instrucción-respuesta del dominio de onboarding en español; ejecución del ajuste fino con LoRA (rango 16, alfa 32) y cuantización de cuatro bits sobre un modelo de código abierto en Google Colab con GPU T4, durante tres épocas; y comparativa de desempeño entre el modelo base y el ajustado, cuya primera iteración ya fue ejecutada con mejora medible. Fase 4 — Cierre (semanas 15 a 16, pendiente): pruebas de integración de extremo a extremo, despliegue en ambiente de demostración, documentación final y preparación de la sustentación.

Representación gráfica del proceso. El panorama metodológico completo se sintetiza en el siguiente flujo, cuya representación gráfica se incluye en los anexos y en el repositorio del proyecto: documento corporativo → extracción de texto → fragmentación con solapamiento → generación de embeddings → indexación vectorial → [consulta del empleado] → filtrado por permisos del usuario → búsqueda semántica → recuperación de los cinco fragmentos más relevantes → agente (recuperar, clasificar, generar) → respuesta con fuentes citadas → evaluación automática de métricas → registro en base de datos → visualización en el panel de Recursos Humanos.

Diseño experimental. Para verificar la hipótesis se aplica un diseño comparativo pre-post sobre el mismo conjunto de prueba: se define un banco de preguntas representativas del dominio de onboarding, cada una con palabras clave esperadas en la

respuesta; cada pregunta se somete al modelo base y al modelo ajustado bajo condiciones idénticas de temperatura y longitud máxima; las respuestas se califican con los indicadores operacionalizados y se comparan los promedios de ambas configuraciones. Este diseño controla las variables intervinientes al mantener fijos el conjunto de prueba, los hiperparámetros de generación y la base documental.

Recolección, organización, sistematización y análisis de los datos. Los datos primarios provienen de dos fuentes recolectadas con instrumentos propios del sistema: las conversaciones registradas entre los usuarios y el agente (pregunta, respuesta, categoría, profundidad y fuentes citadas, almacenadas automáticamente en la base de datos) y las métricas de calidad calculadas por el pipeline de evaluación tras cada interacción y tras cada corrida experimental. Los datos secundarios corresponden a la literatura científica y la documentación técnica oficial referenciadas en la bibliografía. La sistematización es automática: cada registro queda persistido con su marca temporal y trazabilidad completa en el repositorio y la base de datos, lo que elimina la dependencia de registros manuales. Para el análisis se emplean técnicas de estadística descriptiva —promedios, distribuciones por categoría y comparación porcentual entre configuraciones— presentadas de forma numérica y gráfica en el tablero de control de la plataforma. La confiabilidad del instrumento se garantiza porque la aplicación repetida del pipeline de evaluación sobre las mismas entradas, con temperatura controlada, produce resultados consistentes; la validez de las pruebas se sustenta en que los indicadores utilizados corresponden a métricas estandarizadas del framework RAGAS, reconocidas en la literatura para la evaluación de sistemas de generación aumentada.

Estrategia de difusión y divulgación. Los resultados se divulgarán mediante: el repositorio público de código en GitHub con su documentación técnica completa; la sustentación pública del trabajo de grado ante el jurado con demostración funcional de la plataforma; y la disposición del informe final en el repositorio institucional del Politécnico Grancolombiano, como forma de validación y transferencia del trabajo a la comunidad académica.

7. RESULTADOS:

Resultados relacionados con la generación de conocimiento y/o nuevos desarrollos tecnológicos. El producto tecnológico principal es la plataforma SmartOnboard AI, verificable a través del repositorio de código en GitHub y de su despliegue en ambiente de demostración, compuesta por: (a) una aplicación web con doce vistas funcionales que cubren el panel administrativo de Recursos Humanos (tablero de métricas, gestión de empleados, documentos, departamentos y roles, planes de onboarding y configuración del agente) y el portal del empleado (inicio con progreso, chat con el agente, tareas y recursos); (b) una API REST construida con FastAPI, con autenticación JWT, arquitectura multiempresa y control de acceso basado en roles, departamentos y niveles de antigüedad; (c) un pipeline de ingesta y búsqueda semántica de documentos que constituye una base de datos vectorial de conocimiento organizacional consultable en lenguaje natural; (d) un agente conversacional construido con LangGraph que clasifica las consultas por categoría y

profundidad y responde citando las fuentes documentales; (e) un pipeline de evaluación automática de calidad con métricas cuantitativas tipo RAGAS; y (f) los adaptadores LoRA del modelo de lenguaje ajustado al dominio del onboarding en español, junto con el cuaderno de entrenamiento reproducible y el informe comparativo de desempeño entre el modelo base y el especializado. A la fecha de elaboración de este documento, los productos (a) a (d) se encuentran completados y verificados con documentos reales, el producto (e) está implementado y en refinamiento, y del producto (f) se ejecutó la primera iteración con mejora medible en los indicadores de calidad, quedando pendiente su consolidación final.

Resultados conducentes al fortalecimiento de la capacidad científica nacional.

El proyecto contribuye a la formación de recurso humano a nivel profesional mediante el presente trabajo de grado en Ingeniería de Software, que será sustentado ante jurado del Politécnico Grancolombiano. El desarrollo implicó la apropiación de competencias de frontera escasas en el medio nacional —ingeniería de sistemas RAG, construcción de agentes con LangGraph, ajuste fino eficiente de modelos de lenguaje y evaluación automática de sistemas generativos— documentadas de forma reproducible en el repositorio del proyecto, lo que permite que otros estudiantes e investigadores de la institución las utilicen como material de referencia.

Resultados dirigidos a la apropiación social del conocimiento. Como estrategias de divulgación y transferencia se entregan: el repositorio público de código con documentación técnica completa (guías de instalación, arquitectura, credenciales de demostración y manual de uso), que permite a cualquier organización o desarrollador desplegar y adaptar la solución; la demostración funcional de la plataforma durante la sustentación pública del trabajo de grado; y el informe final disponible en el repositorio institucional, que sistematiza tanto los fundamentos teóricos como las decisiones de ingeniería para beneficio de la comunidad académica y del sector productivo interesado en la adopción de inteligencia artificial en procesos de gestión humana.

Impactos esperados a partir del uso de los resultados. En la categoría económica y de productividad, la adopción de la plataforma permitiría reducir el tiempo de incorporación efectiva de los empleados —en el escenario de demostración, de 6,3 a 4,2 días en promedio— y liberar horas del personal de Recursos Humanos hoy dedicadas a resolver consultas repetitivas, con una tasa de resolución automática superior al noventa por ciento en el ambiente de pruebas; a mediano plazo, la arquitectura multiempresa habilita su explotación como producto de software como servicio por parte de emprendimientos locales. En la categoría de competitividad, el proyecto demuestra que es viable construir, especializar y evaluar sistemas de inteligencia artificial con herramientas de código abierto y costos marginales, lo que reduce barreras de adopción para las pequeñas y medianas empresas colombianas. En la categoría social, un acompañamiento permanente, en lenguaje natural y con fuentes verificables, mejora la experiencia y reduce la incertidumbre de los nuevos empleados, con independencia de horarios y modalidades de trabajo remoto. En la categoría ambiental, la elección de técnicas de ajuste fino eficiente y modelos compactos minimiza el consumo computacional y energético frente al reentrenamiento completo de modelos, estableciendo una práctica de inteligencia artificial sostenible replicable en proyectos futuros.

8. CRONOGRAMA

Fase / Actividad	Semanas	Inicio	Fin	Horas/hombre	Estado
Fase 1 — Backend y pipeline RAG (OE1)	1–6	30/03/2026	10/05/2026	120	Completada
Configuración de entorno, repositorio y estructura del proyecto	1–2	30/03/2026	12/04/2026	30	Completada
Modelado de datos, autenticación JWT y API REST con RBAC	2–5	06/04/2026	03/05/2026	55	Completada
Pipeline de ingesta: extracción, fragmentación y embeddings	4–6	20/04/2026	10/05/2026	35	Completada
Fase 2 — Agente conversacional y frontend (OE2, OE3)	6–10	04/05/2026	07/06/2026	100	Completada
Agente LangGraph (ReAct): recuperación,	6–8	04/05/2026	24/05/2026	45	Completada

clasificación y generación					
Frontend Next.js (12 vistas) e integración con la API	8–10	18/05/2026	07/06/2026	55	Completada
Fase 3 — Evaluación y ajuste fino (OE4)	11–15	08/06/2026	12/07/2026	70	En ejecución
Pipeline de evaluación automática (métricas tipo RAGAS)	11–12	08/06/2026	21/06/2026	30	En ejecución
Ajuste fino con LoRA y comparativa base vs. especializado	13–15	22/06/2026	12/07/2026	40	Primera iteración ejecutada
Fase 4 — Cierre, documentación y sustentación	15–16	06/07/2026	19/07/2026	30	Pendiente
Pruebas de integración y despliegue en ambiente de demostración	15	06/07/2026	12/07/2026	15	Pendiente
Informe final y preparación de la sustentación	16	13/07/2026	19/07/2026	15	Pendiente

9. BIBLIOGRAFÍA

- [1] P. Lewis y otros, "Generación aumentada por recuperación para tareas de procesamiento de lenguaje natural con alta demanda de conocimiento" (Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks), en Avances en Sistemas de Procesamiento de Información Neuronal (NeurIPS), 2020.
- [2] E. J. Hu y otros, "LoRA: Adaptación de bajo rango para modelos de lenguaje de gran escala" (LoRA: Low-Rank Adaptation of Large Language Models), en Conferencia Internacional sobre Representaciones del Aprendizaje (ICLR), 2022.
- [3] A. Das, "RAGAS: kit de herramientas de evaluación de pipelines RAG impulsado por modelos de lenguaje", Medium, 2025. [En línea]. Disponible en: <https://medium.com/@AbhishekDas92/ragas-llm-powered-evaluation-toolkit-for-rag-pipelines-34717e1a7210>. [Consultado: junio de 2026].
- [4] Google Research, "ReAct: synergizando el razonamiento y la actuación en modelos de lenguaje", Blog de Google Research, 2023. [En línea]. Disponible en: <https://research.google/blog/react-synergizing-reasoning-and-acting-in-language-models/>. [Consultado: junio de 2026].
- [5] LangChain AI, "Descripción general de LangGraph: diseño de agentes que manejan tareas complejas de forma confiable", Documentación oficial, 2026. [En línea]. Disponible en: <https://docs.langchain.com/oss/python/langgraph/overview>. [Consultado: junio de 2026].
- [6] Hugging Face, "PEFT: ajuste fino eficiente en parámetros para modelos de lenguaje de gran escala", Documentación oficial, 2026. [En línea]. Disponible en: <https://huggingface.co/docs/peft>. [Consultado: junio de 2026].
- [7] Meta AI, "Presentación de Meta Llama 3: el modelo de lenguaje de código abierto más capaz hasta la fecha", Blog oficial de Meta AI, 2024. [En línea]. Disponible en: <https://ai.meta.com/blog/meta-llama-3/>. [Consultado: junio de 2026].
- [8] Atlassian, "Documentación de la API REST de Jira versión 3: referencia para integración con sistemas externos", Portal de desarrolladores de Atlassian, 2026. [En línea]. Disponible en: <https://developer.atlassian.com/cloud/jira/platform/rest/v3/>. [Consultado: junio de 2026].
- [9] Congreso de la República de Colombia, Ley Estatutaria 1581 de 2012, "Por la cual se dictan disposiciones generales para la protección de datos personales", Diario Oficial No. 48.587, Bogotá D.C., 18 de octubre de 2012.
- [10] S. Borgeaud y otros, "Mejora de modelos de lenguaje mediante recuperación de información a partir de billones de tokens" (Improving Language Models by Retrieving from Trillions of Tokens), en Actas de la 39.ª Conferencia Internacional sobre Aprendizaje Automático (ICML), 2022.